

# Regressão Não Linear

Modelos de Regressão

August 17, 2024

# Conceito

*"Qualquer modelo que não seja linear nos parâmetros desconhecidos é um **modelo de regressão não linear**" (Montgomery, 2006).*

# Conceito

Neste caso, pode-se seguir três caminhos diferentes:

- 1 linearizar a relação transformando os dados;
- 2 ajustar modelos polinomiais ou splines complexos aos dados;
- 3 **ajustar funções não lineares aos dados.**

# Exemplo

O modelo

$$y = \theta_1 e^{\theta_2 x} + \epsilon$$

é não linear nos parâmetros desconhecidos  $\theta_1$  e  $\theta_2$ . Podendo ser escrito também como

$$y = f(\mathbf{x}, \boldsymbol{\theta}) + \epsilon$$

# Conceito

Nos modelos de regressão não linear pelo menos uma das derivadas da função esperança  $f(\mathbf{x}, \theta)$  depende de um dos parâmetros. Na regressão linear essas derivadas não são função de tais parâmetros desconhecidos.

## Regressão Linear

Modelo:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \epsilon$$

Função esperança:

$$f(\mathbf{x}, \beta)$$

Derivada:  $\frac{\partial f(\mathbf{x}, \beta)}{\partial \beta_j} = x_j$

## Regressão Não Linear

Modelo:

$$y = \theta_1 e^{\theta_2 x} + \epsilon$$

Função esperança:

$$f(\mathbf{x}, \theta)$$

Derivadas:

$$\frac{\partial f(\mathbf{x}, \theta)}{\partial \theta_1} = e^{\theta_2 x}; \quad \frac{\partial f(\mathbf{x}, \theta)}{\partial \theta_2} = \theta_1 x e^{\theta_2 x}$$

# Vantagens

De maneira resumida, os modelos não lineares (MNL) têm as seguintes vantagens sobre os modelos lineares (ML):

- 1 Sua escolha têm sustentação baseada em teoria ou princípios mecanísticos (físicos, químicos ou biológicos) ou qualquer outra informação prévia;
- 2 Certos parâmetros são quantidade de interesse para o pesquisador providos de interpretação;
- 3 São parcimoniosos pois tipicamente possuem menos parâmetros;
- 4 Partem do conhecimento do pesquisador sobre o fenômeno alvo.

# Desvantagens

- 1 Requerem procedimentos iterativos de estimação baseados no fornecimento de valores iniciais para os parâmetros;
- 2 Métodos de inferência são aproximados;
- 3 Exigem conhecimento do pesquisador sobre o fenômeno alvo.

# Modelos de Regressão Não Linear: nota

**Idealmente** um modelo de regressão não linear é escolhido com base em considerações teóricas sobre o problema, o que às vezes faz com que eles sejam usados em situações muito específicas.

Nesse caso, as aplicações mais comuns estão relacionadas a **modelos de crescimento**, tipicamente na área da **biologia** onde plantas e organismo crescem com o tempo.



## Estudo de caso: uma curva de degradação

Um solo foi enriquecido com o herbicida metramitron até a concentração de 100 ng/g. Foi então colocado em 24 recipientes de alumínio, dentro de uma câmara climática a 20°C. Foram selecionados 3 recipientes aleatoriamente em 8 momentos diferentes e a concentração residual de metramitron foi medida.

# Dados

```
x <- "https://www.casaonofri.it/_datasets/degradation.csv"
dataset <- read.csv(x, header=T)
head(dataset, 10)
```

##	Time	Conc
## 1	0	96.40
## 2	10	46.30
## 3	20	21.20
## 4	30	17.89
## 5	40	10.10
## 6	50	6.90
## 7	60	3.50
## 8	70	1.90
## 9	0	102.30
## 10	10	49.20

# Gráfico de dispersão




Figure: Degradação do metamitron no solo.

# Formas de funções

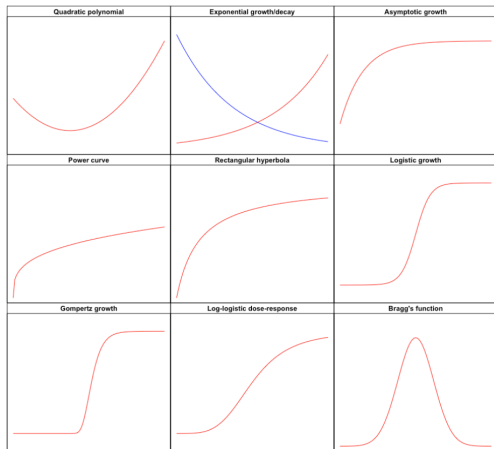


Figure: Formas das funções mais importantes.

# Equações por trás das funções

Name	Equation	R function
Straight line	$Y = b_0 + b_1 X$	<code>NLS.linear()</code>
Quadratic polynomial	$Y = b_0 + b_1 X + b_2 X^2$	<code>NLS.poly2()</code>
Exponential	$Y = a e^{kX}$	<code>NLS.expoGrowth()</code> <code>NLS.expoDecay()</code>
Asymptotic	$Y = a - (a - b) \exp(-cX)$	<code>NLS.asymReg()</code>
Power	$Y = a X^b$	<code>NLS.powerCurve()</code>
Logarithmic	$Y = a + b \log(X)$	<code>NLS.logCurve()</code>
Rectangular hyperbola	$Y = \frac{aX}{b+X}$	<code>SSmicmen()</code>
Logistic	$Y = c + \frac{d-c}{1+\exp(-b(X-e))}$	<code>NLS.L4()</code> <code>NLS.L3()</code> <code>NLS.L2()</code>
Gompertz	$Y = c + (d - c) \exp \{-\exp[-b(X - e)]\}$	<code>NLS.G4()</code> <code>NLS.G3()</code> <code>NLS.G2()</code>
Modified Gompertz	$Y = c + (d - c) \{1 - \exp \{-\exp[b(X - e)]\}\}$	<code>NLS.E4()</code> <code>NLS.E3()</code> <code>NLS.E2()</code>
Log-logistic	$Y = c + \frac{d-c}{1+\exp\{\frac{d-c}{b(\log(X)-\log(e))}\}}$	<code>NLS.LL4()</code> <code>NLS.LL3()</code> <code>NLS.LL2()</code>
Weibull I	$Y = c + (d - c) \exp \{-\exp[-b(\log(X) - \log(e))]\}$	<code>NLS.W1.4()</code> <code>NLS.W1.3()</code> <code>NLS.W1.2()</code>
Weibull II	$Y = c + (d - c) \{1 - \exp \{-\exp[b(\log(X) - \log(e))]\}\}$	<code>NLS.W2.4()</code> <code>NLS.W2.3()</code> <code>NLS.W2.2()</code>
Bragg	$Y = c + (d - c) \exp[-b(X - e)^2]$	<code>NLS.bragg.3()</code> <code>NLS.bragg.4()</code>
Lorentz	$Y = c + \frac{d-c}{1+b(X-e)^2}$	<code>NLS.lorentz.3()</code> <code>NLS.lorentz.4()</code>
Beta	$Y = d \left\{ \left( \frac{X-X_5}{X_6-X_5} \right) \left( \frac{X_6-X}{X_6-X_5} \right)^{\frac{X_6-X_5}{X_5-X_4}} \right\}^b$	<code>NLS.beta()</code>

Figure: Equações e funções no R.

# Modelo

$$Y_i = ae^{-kX_i} + \epsilon_i$$

Onde

$Y$  é a **concentração no tempo  $X$**

$a$  é a **concentração inicial de metamitrona**

$k$  é a **taxa de degradação constante**.



# Estimação dos parâmetros: linearização

```
mod <- lm(log(Conc) ~ Time, data=dataset)
summary(mod)
## Call:
## lm(formula = log(Conc) ~ Time, data = dataset)
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.11738 -0.09583  0.05336  0.31166  1.01243

## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  4.662874    0.257325   18.12 1.04e-14 ***
## Time        -0.071906    0.006151  -11.69 6.56e-11 ***
## Residual standard error: 0.6905 on 22 degrees of freedom
## Multiple R-squared:  0.8613, Adjusted R-squared:  0.855
## F-statistic: 136.6 on 1 and 22 DF,  p-value: 6.564e-11
```

# Estimação dos parâmetros: linearização


```
par(mfrow = c(1,2))  
plot(mod, which = 1)  
plot(mod, which = 2)
```





# Estimação dos parâmetros: aproximação polinomial

```
mod2 <- lm(Conc ~ Time + I(Time^2), data=dataset)
pred <- predict(mod2, newdata = data.frame(Time = seq(0, 70
plot(Conc ~ Time, data=dataset)
lines(pred ~ seq(0, 70, by = 0.1), col = "red")
```





# Estimação dos parâmetros: mínimos quadrados não lineares

```
modNlin <- nls(Conc ~ A*exp(-k*Time),  
               start=list(A=100, k=0.05),  
               data = dataset)  
  
summary(modNlin)  
  
## Formula: Conc ~ A * exp(-k * Time)  
  
## Parameters:  
##      Estimate Std. Error t value Pr(>|t|)  
## A 99.634902    1.461047   68.19  <2e-16 ***  
## k  0.067039    0.001887   35.53  <2e-16 ***  
##  
## Residual standard error: 2.621 on 22 degrees of freedom  
##  
## Number of iterations to convergence: 5  
## Achieved convergence tolerance: 4.22e-07
```


# Ajuste do modelo

```
par(mfrow=c(1,2))  
plot(modNlin, which = 1)  
plot(modNlin, which = 2)
```



# Ajuste do modelo

```
plot(modNlin, type = "means",  
      xlab = "Time(d)", ylab = "Concentration(ng/g)")
```



# Medida de qualidade do ajuste

```
MSE <- summary(modNlin)$sigma ^ 2
MST <- var(dataset$Conc)
1 - MSE/MST
## [1] 0.9936359
```

# Predição

```
func <- list(~A * exp(-k * time))  
const <- data.frame(time = c(5, 10, 15))  
gnlht(modNlin, func, const)
```

##	Form	time	Estimate	p-value
## 1	A * exp(-k * time)	5	71.25873	5.340741e-28
## 2	A * exp(-k * time)	10	50.96413	3.163518e-25
## 3	A * exp(-k * time)	15	36.44947	6.029672e-22

# Referências

MONTGOMERY, Douglas C.; PECK, Elizabeth A.; VINING, G. Geoffrey. **Introduction to Linear Regression Analysis**. 4ª ed. Hoboken: John Wiley Sons, 2006.

NABERGOI, Carlos. **Curso de Modelos Não Lineares em R**. Disponível em: <https://www.ime.unicamp.br/cnaber/cursomodelosnaolinearesR.pdf>. Acesso em: 21 jul. 2024.

STATFORBIOLOGY.COM. **Nonlinear Regression**. Disponível em: <https://www.statforbiology.com/-statbookeng/nonlinear-regression>. Acesso em: 21 jul. 2024.

Obrigada! :)

```
print("sextou")
```